Kümeleme:

KMeans kümeleme analizinde amaç, gözlemleri birbirlerine olan benzerliklerine göre kümelere ayırmaktır, yani kümelerin içerisindeki homojenliği artırmaktır.

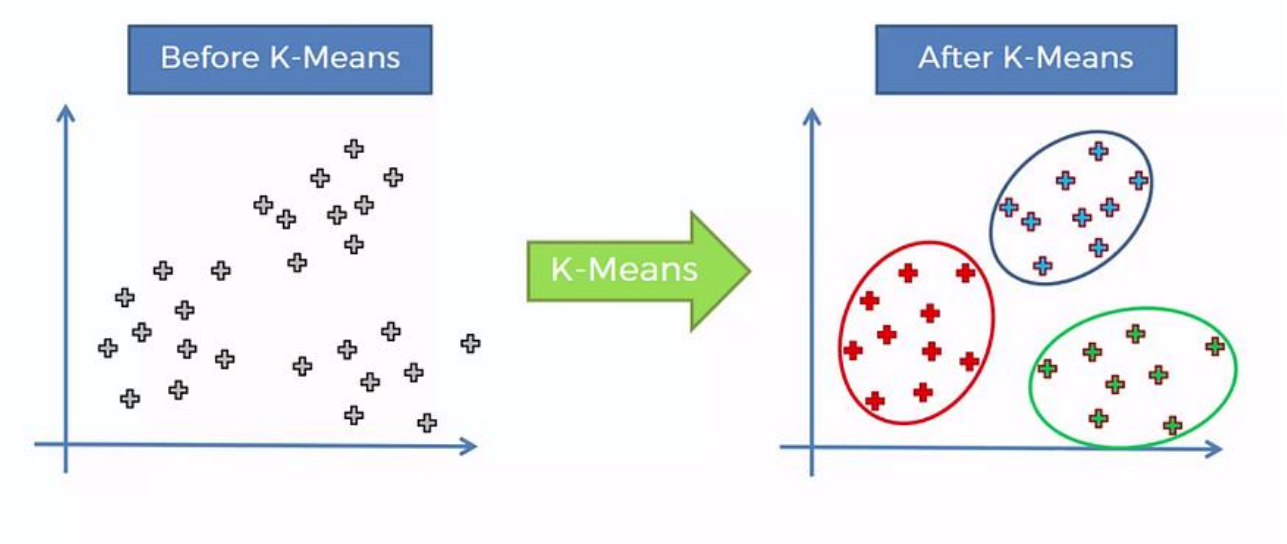

Veri setine uygulanan kümeleme analizinin öncesi ve sonrası

Yukarıdaki şekilde bazı gözlemler, birbirlerine olan yakınlıklarına göre çeşitli uzaklık metriklerini kullanılarak kümelere ayrılmıştır. Sınıflandırma problemlerinden farkı, sınıflandırma problemlerinin sınıflara ayrılmasıdır. Burada ise gözlemler birbirlerine olan benzerliklerine göre kümelere ayrılmaktadır. Yani kümeleme işlemlerinde sınıf bilgisi olmadığından gözlem birimleri kendi içerisinde birbirlerine olan benzerliklerine göre gruplara ayrılır.

KMeans yöntemi nasıl çalışır?

Adim 1: Küme sayısı belirlenir (örneğin 5 küme)

Adim 2: Rastgele k adet merkez seçilir (dolayısıyla 5 merkez).
Adim 3: Her gözlem için k merkezlere olan uzaklıklar hesaplanır.
Adim 4: Her gözlem en yakın olan merkeze yani kümeye atanır.
Adim 5: Atama merkezlerinden sonra oluşan kümeler için tekrar merkez hesaplamaları yapılır. Bu adim oldukça kritiktir.
Adim 6: Bu işlem, belirlenen bir iterasyon adedince tekrar edilir küme için hata kareler toplamlarının toplamının (total within-cluster variation) minimum olduğu durumdaki gözlemlerin kümelenme yapısı, nihai kümelenme olarak seçilir.

Küme yapısının belirlenmesi ve rastgele k adet merkez seçilmesi, bu yöntemin dezavantajlarıdır.

Kütüphaneleri import etme:

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.cluster import KMeans
from sklearn.preprocessing import StandardScaler, MinMaxScaler
from yellowbrick.cluster import KElbowVisualizer
import warnings
warnings.filterwarnings("ignore")

from IPython.core.interactiveshell import InteractiveShell
InteractiveShell.ast_node_interactivity = 'all'
```

```
pd.set_option('display.max_columns', None)
pd.set_option('display.width', 500)
```

Veri setini import etme

```
df = pd.read_csv('/kaggle/input/us-arrests/us_arrests.csv', index_col=0)
```

Veri setinin sıfırıncı indeksinde indeks bilgisi olduğundan dolayı index_col=0 yapılır.

Veri setini anlama

Veri setini kontrol etmek için aşağıdaki check_dataframe fonksiyonunu kullanabilirsiniz.

```
def check_dataframe(dataframe, head=5):
    print("Dataset Info:".upper())
    display(dataframe.head(head))
    print("\nShape:", dataframe.shape)
    print("\nData Types:\n", dataframe.info())
    print("\nMissing Values:\n",
dataframe.isnull().sum().sort_values(ascending=False))
    print("\nDescriptive Statistics:\n", dataframe.describe([0.05, 0.10, 0.25,
0.50, 0.75, 0.90, 0.95, 0.99]).T)

check_dataframe(df)
```

DATASET INFO:

	state	Murder	Assault	UrbanPop	Rape	cluster
0	Alabama	13.2	236	58	21.2	2
1	Alaska	10.0	263	48	44.5	3
2	Arizona	8.1	294	80	31.0	6
3	Arkansas	8.8	190	50	19.5	5
4	California	9.0	276	91	40.6	3

Veri setinin ilk 5 gözlemi:

```
Shape: (50, 6)
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 50 entries, 0 to 49
Data columns (total 6 columns):
 #   Column    Non-Null Count  Dtype
---  ------    --------------  -----
 0   state     50 non-null     object
 1   Murder    50 non-null     float64
 2   Assault   50 non-null     int64
 3   UrbanPop  50 non-null     int64
 4   Rape      50 non-null     float64
 5   cluster   50 non-null     int32
dtypes: float64(2), int32(1), int64(2), object(1)
memory usage: 2.3+ KB

Data Types:
 None

Missing Values:
 state       0
Murder      0
Assault     0
UrbanPop    0
Rape        0
cluster     0
dtype: int64
```

Veri setinin gözlem ve değişken sayıları ile birlikte veri yapıları ve bos gözlemin olup olmadığı

	count	mean	std	min	5%	10%	25%	50%	75%	90%	95%	99%	max
Murder	50.0	7.788	4.355510	0.8	2.145	2.56	4.075	7.25	11.250	13.32	15.400	16.763	17.4
Assault	50.0	170.760	83.337661	45.0	50.250	56.90	109.000	159.00	249.000	279.60	297.300	336.020	337.0
UrbanPop	50.0	65.540	14.474763	32.0	44.000	45.00	54.500	66.00	77.750	83.20	86.550	90.020	91.0
Rape	50.0	21.232	9.366385	7.3	8.750	10.67	15.075	20.10	26.175	32.40	39.745	45.265	46.0
cluster	50.0	3.700	1.705334	1.0	1.000	1.00	2.000	4.00	5.000	6.00	6.000	6.000	6.0

Veri setinin tanımlayıcı istatistikler

Bu veri seti, Amerika Birleşik Devletleri'nin 50 eyaletinde cinayet, saldırı, kentsel nüfus ve tecavüz suçlarının yıllık oranlarını içermektedir. Veri setinde hiçbir eksik değer bulunmamaktadır.

Saldırı, ortalama 170,76 ile en yüksek ortalama değere sahip suçtur. Aynı zamanda standart sapması da yüksektir, bu da eyaletler arasındaki saldırı suçu oranlarının diğer suç oranlarından daha farklı olabileceğini göstermektedir.

Murder suç oranı ortalaması 7,78'dir ve standart sapması 4,36'dır. Rape suçu ortalaması 21,23'tür ve standart sapması 9,37'dir. Bu suç oranları, saldırı suçu kadar yüksek değildir, ancak yine de önemli düzeydedir.

UrbanPop, ortalama 65,54 ile en düşük suç oranına sahiptir. Ancak veri setinde kentsel nüfusun suç oranları üzerindeki etkisini açıklamak için yeterli bilgi yoktur.

Tanımlayıcı istatistiklerdeki değerler, bu verilerin özellikleri hakkında daha fazla bilgi sağlar. Örneğin, cinayet oranı en düşük olan eyalette (Minnesota), en yüksek olan eyalet (Louisiana) arasında değişirken, diğer özelliklerde de farklılıklar görülmektedir. Saldırı oranı en düşük olan eyalette (Maine), en yüksek olan eyalet (Nevada) arasında değişirken, tecavüz oranı en düşük olan eyalette (North Dakota), en yüksek olan eyalet (Alaska) arasında değişir. Ayrıca, şehir nüfusu en az olan eyalette (Vermont), en fazla olan eyalette (California) arasında değişmektedir.

Bu veri setindeki bilgiler, suç oranları üzerine analiz yapmak isteyenler için faydalı olabilir.

Verilerin standartlaştırılması

Uzaklık ve gradient descent temelli yöntemlerin kullanımındaki süreçlerde değişkenlerin standartlaştırılması önemlidir. Dolayısıyla buradaki değişkenlerde standartlaştırılmalıdır. Verileri 0–1 arasındaki değerlere dönüştürmek için MinMaxScaler kullanabilirsiniz.

```
mms = MinMaxScaler(feature_range=(0, 1))
df = mms.fit_transform(df)  # Bu islem sonrasinda numpy arrayi elde edilir.
df[0:5]
```

```
array([[0.74698795, 0.65410959, 0.44067797, 0.35917313],
       [0.55421687, 0.74657534, 0.27118644, 0.96124031],
       [0.43975904, 0.85273973, 0.81355932, 0.6124031 ],
       [0.48192771, 0.49657534, 0.30508475, 0.31524548],
       [0.4939759 , 0.79109589, 1.        , 0.86046512]])
```

Veriler, fit_trasnform() prosesinden çıktıktan sonra numpy arrayine dönüştürülür. Dolayısıyla ilk 5 gözleme bakmak için df[0:5] kullanılır.

Model kurma

```
kmeans = KMeans(n_clusters=4, random_state=0).fit(df)
```

Model kurma işlemi tamamlandıktan sonra modelin hiperparametreleri get_params() metodunun kullanarak elde edilir.

```
print(f'KMeans modelinin hiperparemetreleri: \n{kmeans.get_params()}')
```

```
KMeans modelinin hiperparemetreleri:
{'algorithm': 'auto', 'copy_x': True, 'init': 'k-means++', 'max_iter': 300, 'n_cl
usters': 4, 'n_init': 10, 'random_state': 0, 'tol': 0.0001, 'verbose': 0}
```

Yukarıdaki parametrelere göre dışarıdan ayarlanması gereken en önemli hiperparametre n_clusters'tir. Küme sayları aşağıdaki kodlama kullanılarak elde edilebilir.

```
print(f"KMeans modelinin küme sayısı: {kmeans.n_clusters}'tür.")

# KMeans modelinin küme sayısı: 4'tür.
```

Küme merkezlerini belirleme

Küme merkezlerini belirlemek için aşağıdaki kodlama kullanılır. Nihai olarak belirlenen 4 kümenin merkezleri gelir. Yani standartlaştırılmış değerlerdeki birer gözlem birimidir.

```
print(f'KMeans modelinin küme merkezleri: \n{kmeans.cluster_centers_}')
```

```
KMeans modelinin küme merkezleri:
[[0.6124498  0.75       0.75423729 0.67980189]
 [0.30439405 0.32937147 0.70588235 0.31098951]
 [0.79141566 0.6802226  0.36864407 0.36466408]
 [0.1686747  0.11485774 0.34028683 0.12601868]]
```

Belirlenen kümelerin küme etiketlerini (labels) getirme

Bu işlem aşağıdaki gibi yapılır. Elde edilen sonuca göre 0'dan 3'e kadar 4 küme/labels vardir. 0, ilk kümeyi, 3 ise son kümeyi temsil eder. Dolayısıyla bunlar, veri setindeki her bir gözlemin kmeans modeli tarafından belirlenen kümeleridir.

```
print(f'Belirlenen kümelerin küme etiketleri: \n{kmeans.labels_}')
```

```
Belirlenen kümelerin küme etiketleri:
[2 0 0 2 0 0 1 1 0 2 1 3 0 1 3 1 3 2 3 0 1 0 3 2 1 3 3 0 3 1 0 0 2 3 1 1 1
 1 1 2 3 2 0 1 3 1 1 3 3 1]
```

Hata değerlerini (SSD, SSE, SSR) hesaplama

Bu işlem için inertia_ metodu kullanılır. inertia_, örneklerin en yakın küme merkezine olan uzaklıklarının karelerinin toplamını ifade eder.

```
print(f"KMeans modelinin hatası: {round(kmeans.inertia_, 2)}'dir.")

# KMeans modelinin hatası: 3.68'dir.
```

Optimum küme sayısını belirleme

n_clusters hiperparametresinin ön tanımlı değeri 8'dir. Öyle bir işlem yapılmalı ki farklı k parametre değerlerine göre SSD incelenmeli ve SSD'ye göre karar verilmelidir. Bu işlem aşağıdaki gibidir.

```
kmeans = KMeans()   # boş bir KMeans nesnesi oluşturma
ssd = []            # ssd isimli bos bir liste oluşturma
K = range(1, 30)    # 1'den 30'a kadar K değerlerini oluşturma

# Döngü aracılığıyla işlemleri gerçekleştirme
for k in K:
    kmeans = KMeans(n_clusters = k).fit(df)
    ssd.append(kmeans.inertia_)

# ssd değerlerini görselleştirme
plt.plot(K, ssd)
plt.xlabel('K değerleri')
plt.ylabel('SSD')
plt.title('Elbow Methodu ile SSD değerlerini görselleştirme')
plt.show()
```

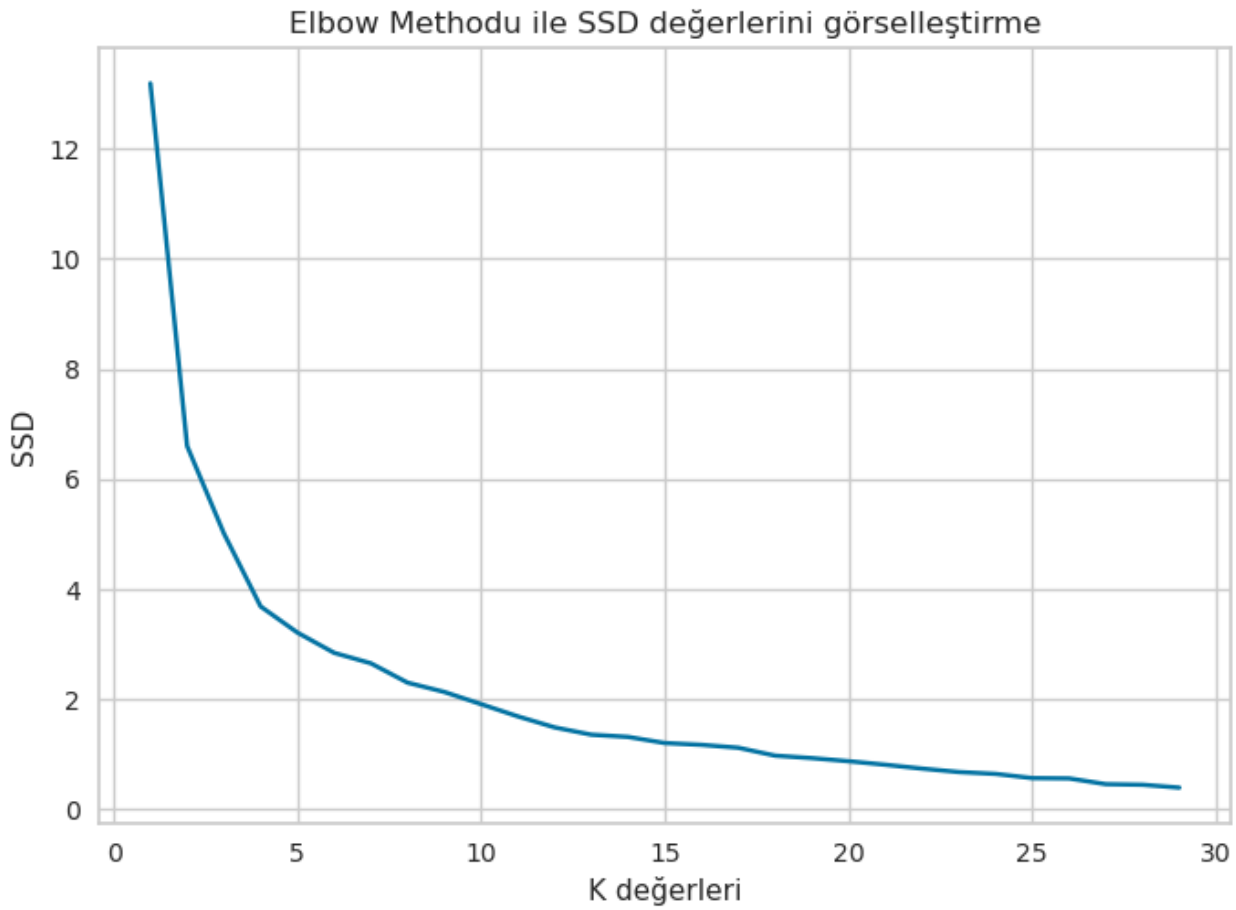

Yukarıdaki grafiğe göre, küme sayısı arttıkça SSD değerleri azalır. Dolayısıyla burada bir karar vermek gerekirse k değeri 5 olarak belirlenebilir. Gözlem birimi kadar küme olduğunda SSD değeri sıfır olur. Çünkü bütün gözlem birimleri bir küme ve her bir gözlem birimi de bir merkez olur. Dolayısıyla SSD=0 olur. Küme sayısı arttıkça hatanın düşmesi beklenir. Bu durumda ne yapılmalıdır? Pratikte gözlem birimlerinin hepsiyle belirli bir hareket tarzı, aksiyonu gerçekleştirilemediğinden dolayı kümelere ayırmak istediğimiz için organik olarak 3, 4, 5, belki 7, 8 gibi küme olması gerekir ki bu gruplara göre hareket edilmesi gerekir. Öte yandan, KMeans ve Hiyerarşik kümeleme gibi yöntemler kullanılırken algoritmanın verdiği referanslara göre (SSD) olan küme sayılarına doğrudan bakılarak işlem yapılmamalıdır. Çalışmanın başında is bilgisi de ne kadar küme

yapılacağı hakkında ön fikir olmalıdır. Bu duruda matematiksel temeller için makine öğrenmesi modelleri kullanılır. Örneğin, veri setinde 40 tane değişkenin olduğunu ve bu değişkenleri kullanarak kümeleme yapılması gerektiğini düşünelim. Ancak, kümelemeyi göz yordamıyla yapmak mümkün değildir. O yüzden matematiksel bir metot gerekmektedir. Dolayısıyla kümeleme yöntemlerinden biri olan KMeans yöntemi kullanılabilir. Yukarıdaki sekil, merkez sayısını belirlemede bir sinyal vermektedir. Ancak, bu kesin olarak belirlenemeyebilir. Bu durumda optimum noktayı belirlemek için aşağıdaki yöntem kullanılabilir.

ElbowVisualizer yöntemine göre optimum küme sayısını belirleme

```
kmeans = KMeans()
elbow = KElbowVisualizer(kmeans, k=(2, 20))
elbow.fit(df)
elbow.show()
```

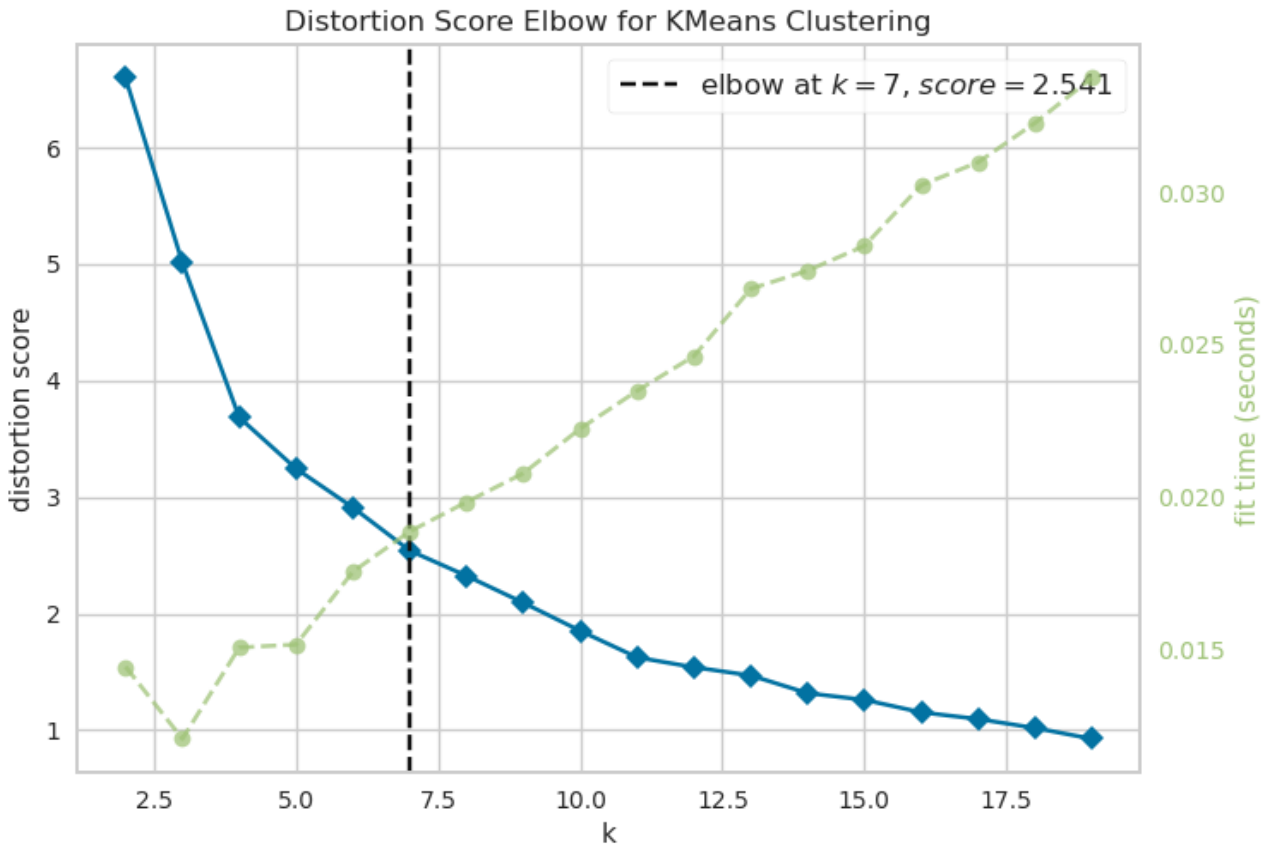

Optimum k değerini elde etme

```
print(f"Optimum k değeri: {elbow.elbow_value_}'dir.")

# Optimum k değeri: 7'dir.
```

KMeans final modeli

Final kümelerinin oluşturulması

```
kmeans = KMeans(n_clusters=elbow.elbow_value_).fit(df)
print(f'Küme sayısı: {kmeans.n_clusters}.\n')
print(f'Küme merkezleri: \n{kmeans.cluster_centers_}\n')
```

```
print(f'Küme etiketleri: \n{kmeans.labels_}')   # 0'dan 5'e kadar küme olusturulur.
```

```
Küme sayısı: 7.

Küme merkezleri:
[[0.83562823 0.70645793 0.37772397 0.37172388]
 [0.29682366 0.23505604 0.48382126 0.22973925]
 [0.5686747  0.70205479 0.71864407 0.87028424]
 [0.22289157 0.27853881 0.87288136 0.23169681]
 [0.64371773 0.78424658 0.77966102 0.54374308]
 [0.11445783 0.06898239 0.24213075 0.06681432]
 [0.34939759 0.40704501 0.63922518 0.40789959]]

Küme etiketleri:
[0 2 4 1 2 2 3 6 4 0 3 1 4 1 5 1 1 0 5 4 3 2 1 0 6 1 1 2 5 3 4 4 0 5 6 6 6
 1 3 0 5 0 4 3 5 6 6 5 1 1]
```

Hangi gözlem biriminin hangi kümeye ait olduğunu belirleme

```
clusters_kmeans = kmeans.labels_
df = pd.read_csv('/kaggle/input/us-arrests/us_arrests.csv', index_col=0)
df['cluster'] = clusters_kmeans + 1     # veri setine yeni değişken ekleme
df.head()
```

	Murder	Assault	UrbanPop	Rape	cluster
Alabama	13.2	236	58	21.2	1
Alaska	10.0	263	48	44.5	3
Arizona	8.1	294	80	31.0	5
Arkansas	8.8	190	50	19.5	2
California	9.0	276	91	40.6	3

Hangi eyaletin hangi kümeye ait olduğunu belirleme

```
df = df.reset_index()
df.rename(columns = {'index':'state'}, inplace = True)
for i in df['cluster'].unique():
    print(f'\nKüme numarasi {i} olan eyaletler')
    print(df['state'][df['cluster'] == i])
```

```
Küme numarasi 1 olan eyaletler
0            Alabama
9            Georgia
17         Louisiana
23       Mississippi
32    North Carolina
39    South Carolina
41         Tennessee
Name: state, dtype: object
Küme numarasi 3 olan eyaletler
1          Alaska
4      California
5        Colorado
21       Michigan
27         Nevada
Name: state, dtype: object
```

```
Küme numarasi 5 olan eyaletler
2         Arizona
8         Florida
12       Illinois
19       Maryland
30     New Mexico
31       New York
42          Texas
Name: state, dtype: object
```

```
Küme numarasi 2 olan eyaletler
3          Arkansas
11            Idaho
13          Indiana
15           Kansas
16         Kentucky
22        Minnesota
25          Montana
26         Nebraska
37     Pennsylvania
48        Wisconsin
49          Wyoming
Name: state, dtype: object
```

```
Küme numarasi 4 olan eyaletler
6        Connecticut
10            Hawaii
20     Massachusetts
29        New Jersey
38      Rhode Island
43              Utah
Name: state, dtype: object
```

```
Küme numarasi 7 olan eyaletler
7       Delaware
24      Missouri
34          Ohio
35      Oklahoma
36        Oregon
45      Virginia
46    Washington
Name: state, dtype: object

Küme numarasi 6 olan eyaletler
14            Iowa
18           Maine
28    New Hampshire
33     North Dakota
40     South Dakota
44          Vermont
47    West Virginia
Name: state, dtype: object
```

KMeans kümelemede segmentler neye göre oluşturulur?

K-Means kümeleme, verilerin özelliklerine göre yapılan ölçümlerle benzer verilerin aynı kümede toplanmasını sağlar. Bununla beraber, değişkenler standardize edilmektedir. Bu sayede verilerin segmentler halinde gruplandırılması ve farklı özelliklere sahip verilerin ayrılması mümkün olur.

```
df.groupby('cluster').agg(['count', 'mean', 'median'])
```

	Murder			Assault			UrbanPop			Rape		
	count	mean	median	count	mean	median	count	mean	median	count	mean	median
cluster												
1	7	14.671429	14.4	7	251.285714	249.0	7	54.285714	58.0	7	21.685714	22.20
2	11	5.727273	6.0	11	113.636364	109.0	11	60.545455	62.0	11	16.190909	16.30
3	5	10.240000	10.0	5	250.000000	255.0	5	74.400000	78.0	5	40.980000	40.60
4	6	4.500000	3.9	6	126.333333	134.5	6	83.500000	84.0	6	16.266667	17.55
5	7	11.485714	11.3	7	274.000000	285.0	7	78.000000	80.0	7	28.342857	27.80
6	7	2.700000	2.2	7	65.142857	57.0	7	46.285714	45.0	7	9.885714	9.50
7	7	6.600000	6.6	7	163.857143	156.0	7	69.714286	70.0	7	23.085714	21.40

Yukarıdaki tablo, bir veri kümesinin K-Means kümeleme algoritması kullanılarak 6 farklı küme (cluster) halinde segmentlere ayrılması sonucunu göstermektedir. Kümeleme işlemi, dört farklı özellik (Murder, Assault, UrbanPop, Rape) üzerinde gerçekleştirilmiştir. Tabloda her küme için özelliklerin sayısı, ortalaması ve medyanı verilmiştir.

“count” sütunu, her bir kümede kaç adet verinin olduğunu göstermektedir.
“mean” sütunu, her bir kümenin o özellik için ortalama değerini vermektedir.
“median” sütunu, her bir kümenin o özellik için ortanca değerini vermektedir.

Örneğin, “cluster 1” için Murder özelliği için ortalama değer 2.68, medyan değeri 2.4 olarak belirtilmiştir. Bu kümede 10 veri bulunmaktadır. Aynı

şekilde Assault özelliği için ortalama değer 70.1, medyan değeri 64.5'tir. UrbanPop özelliği için ortalama değer 51.0, medyan değeri 52.5'tir. Rape özelliği için ise ortalama değer 10.91, medyan değeri 11.0 olarak belirtilmiştir. Benzer yorumlar diğer kümeler için de yapılabilir.

Öte yandan, yukarıdaki tablo, verilerin farklı özelliklerine göre kümelere ayrılmasını göstermektedir. Her bir kümenin özelliklerinin ortalaması ve medyanı, bu kümenin diğer kümelere göre nasıl bir farklılık gösterdiğini anlamak için kullanılabilir. Örneğin, “cluster 2” Assault özelliği için ortalama değeri en yüksek kümedir. Benzer şekilde, “cluster 6” Rape özelliği için en yüksek ortalama değere sahip kümedir.

Çalışmanın bundan sonraki aşaması, bir sınıflandırma problemi olarak devam ettirilip bazı özellik çıkarımları gerçekleştirildikten sonra makine öğrenmesi modeli oluşturulup gelecekle ilgili tahminleme yapılabilir.