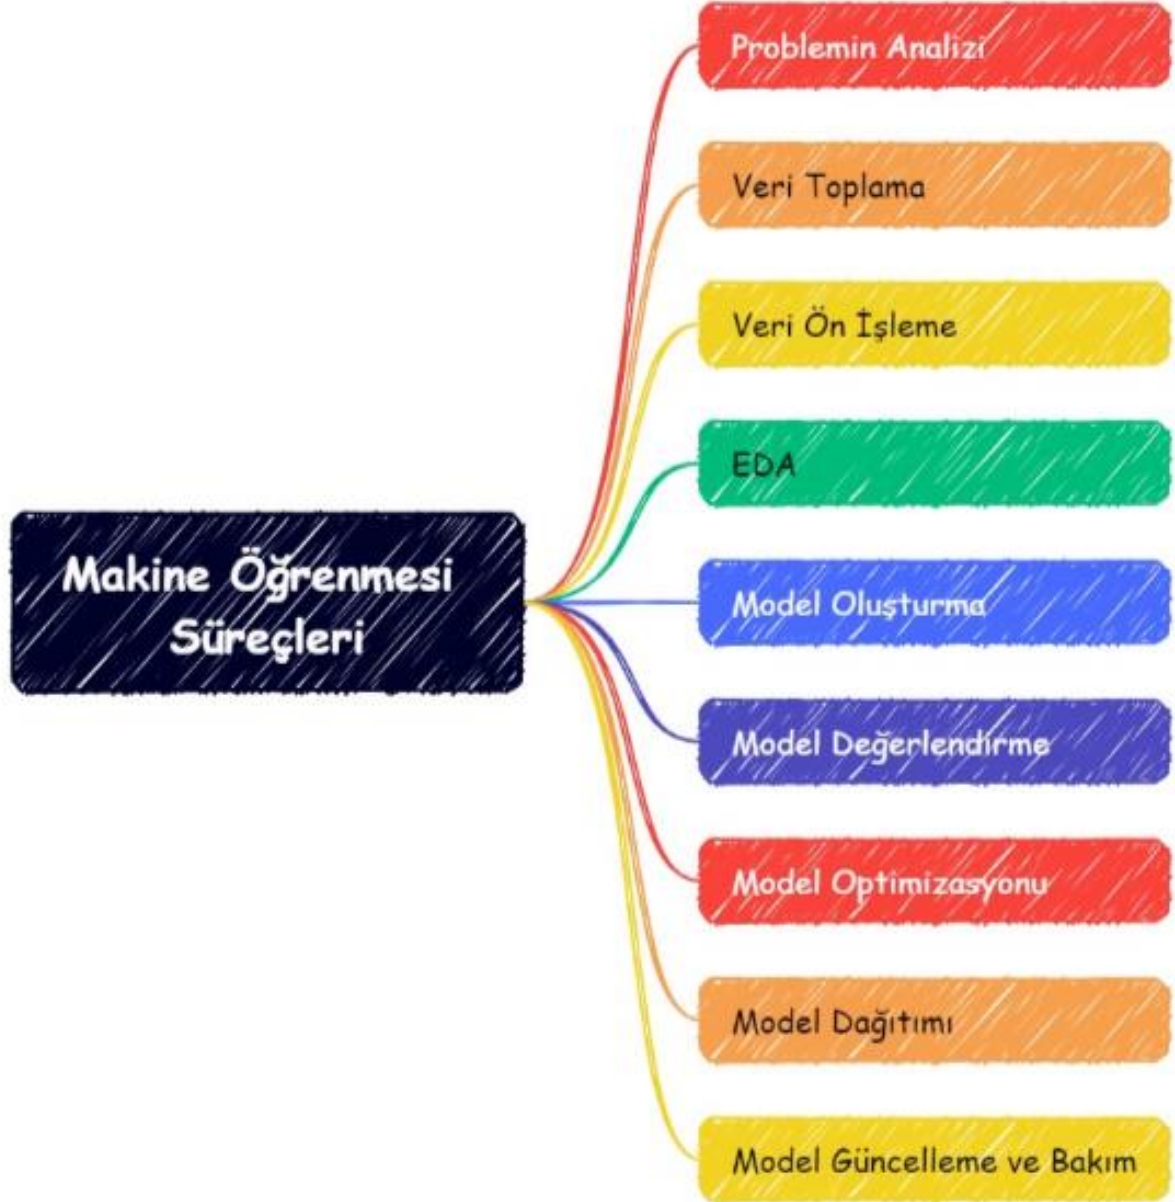


Makine Öğrenmesi Temel Kavramlar:

Öğrenme Süreçleri:



1.Problemin Analizi:

- Problemin Önemi ve Etkisi
- Problemin Doğası
- Başarı Kriterlerinin Belirlenmesi

2.Veritoplama:

- Potansiyel Veri Kaynaklarının Belirlenmesi
- Toplanan Verinin Doğruluğunun ve Temizliğinin Değerlendirilmesi
- Etik ve Yasal Kısıtlamaların Göz Önüne Alınması

3. Veri Ön İşleme:

- Eksik ve Aykırı Değerlerin İşlenmesi
- Veri Dönüşüm ve Normalizasyonu
- Feature Engineering ve Encoding Yöntemleri

4. Keşifsel Veri Analizi(EDA):

- Veri Setinin İstatistiksel Özetlerini Oluşturma
- Görselleştirme Teknikleri ile Veri Yapısının İncelenmesi
- Özelliklerin İlişkilerinin Analizi ve Korelasyon Analizi

5. Model Oluşturma:

- Algoritma Seçimi ve Veri Setinin Eğitim ve Test Verilerine Bölünmesi
- Model Eğitimi ve Değerlendirilmesi
- Hiperparametre Ayarlama ve Tuning

6. Model Değerlendirme:

- Performans Metriklerinin Seçimi ve Uygulanması Doğru Metrikler
- Confusion Matrix, ROC Eğrisi ve AUC Değerlendirmesi
- Modelin Genelleştirme Kabiliyetinin Değerlendirilmesi

7. Model Optimizasyonu:

- Hiperparametre Optimizasyon Yöntemleri
- Feature Selection ve Dimensionality Reduction Teknikleri
- Ensemble Metodlar ve Stacking

8.Modeli Deploy Etme:

- Modelin Üretim Ortamına Taşınması
- API'ler ve Servis Aracılığıyla Erişebilirlik
- Performans ve Ölçeklenebilirlik Optimizasyonu

9.Model Güncelleme ve Bakım

- Modelin Sürekli İzlenmesi ve Değerlendirilmesi
- Modelin Güncellenmesi ve İyileştirilmesi
- Yenilikçi Yaklaşımlar ve Teknolojilerin Entegrasyonu

1. Problemin Analizi ve Çözüm Yolu Tasarımı

Her makine öğrenimi projesi, çözülmesi gereken bir problemle başlar. Bu aşama, projenin temelini atmanıza yardımcı olur.

1.1. Problemin Önemi ve Etkisi

- Problemi çözmenin neden önemli olduğunu belirleyin.
- Çözümün potansiyel faydalarını ve etkilerini değerlendirin.
- Hedef kitleyi ve çözümün bu kitle üzerindeki olası etkilerini tanımlayın.

1.2. Problemin Doğası

- Problemin türünü belirleyin. Örneğin, sınıflandırma, regresyon, kümeleme vb.
- Problemin özelliklerini ve yapısal öğelerini inceleyin.
- Problemin karmaşıklığını değerlendirin, örneğin, algoritmik zorluklar, feature engineering (özellik mühendisliği) gereksinimleri vs.

1.3. Başarı Kriterlerinin Belirlenmesi

- Projenin başarılı sayılabilmesi için hangi kriterlere ulaşması gerektiğini belirleyin.
- Seçilen metrikleri ve performans ölçütlerini tanımlayın. Örneğin; R2, RMSE, MSE, accuracy, recall, vb.
- Başarı kriterlerini ölçebilmek için gereken testler ve değerlendirmeleri planlayın.

İpuçları

Tüm bu süreçleri planlarken problemin doğru bir şekilde tanımlanması için ilgili paydaşların görüşlerini alın. Bu, projenin başarısı için kritik öneme sahiptir.

Benzer problemleri ve çözümleri araştırarak literatür taraması yapın. Bu, size projenizi nasıl daha iyi yapabileceğiniz konusunda fikir verebilir.

Örnek Uygulama

Bir e-ticaret sitesi için ürün tavsiye sistemi geliştirme problemi

- **Problemin Önemi:** Kullanıcıların ilgisini çekebilecek ürünleri önererek satışları artırmak.
- **Problemin Doğası:** Sınıflandırma ve/veya regresyon problemi olarak modellenebilir.
- **Başarı Kriterleri:** Önerilen ürünlerin tıklanma oranı, satın alma dönüşüm oranı gibi metriklerle ölçülebilir.

Problemin doğru bir şekilde tanımlanması, projenin diğer aşamalarını doğru bir şekilde gerçekleştirebilmek adına kritik öneme sahiptir. Bu aşama, projenin yönünü belirler ve başarı kriterlerini oluşturur.

2. Bilgi Denizinden Veri Toplama

Veri toplama, makine öğrenimi projelerinin başlangıç aşamasıdır ve modelin başarısı büyük ölçüde bu aşamadan elde edilen verilere bağlıdır.

2.1. Potansiyel Veri Kaynaklarının Belirlenmesi

- Kullanılabilir veri kaynaklarını araştırın ve listeleyin.
- Veri kaynaklarının güvenilirliğini ve geçerliliğini değerlendirin.
- Veri setinin boyutunu ve kapsamını belirleyin.

2.2. Toplanan Verinin Doğruluğunun ve Temizliğinin Değerlendirilmesi

- Verinin eksik, yanıltıcı veya hatalı olup olmadığını kontrol edin.
- Veri kalitesini artırmak için gerekli temizlik işlemlerini planlayın.
- Veri toplama sürecinde karşılaşılabileceğiniz problemleri öngörün.

2.3. Etik ve Yasal Kısıtlamaların Göz Önüne Alınması

- Veri toplama sürecinin yasalara uygun olmasını sağlayın.
- Kişisel verilerin korunması ve kullanımı ile ilgili düzenlemelere uyun.
- Etik kuralları gözetin ve izin alınması gereken durumları belirleyin.

İpuçları

Farklı türde ve kaynaktan veri toplayarak modelin genelleştirme kabiliyetini artırabilirsiniz.

Web scraping gibi otomatik veri toplama yöntemleri veya çeşitli platformlarda sunulan data setleri kullanarak büyük veri setleri oluşturabilirsiniz.

Örnek Uygulama

Sağlık sektöründe hastalık teşhisi için kullanılabilecek veri setlerinin toplanması

- **Potansiyel Veri Kaynakları:** Hastane kayıtları, sağlık uygulamaları, genetik veri tabanları vb.

- **Veri Doğruluğu ve Temizliği:** Eksik veya yanıltıcı bilgilerin düzeltilmesi, gizlilik ihlali olmadan verinin temizlenmesi.

- **Etik ve Yasal Kısıtlamalar:** Hastaların gizliliğinin korunması, verinin anonimleştirilmesi, izin ve onayların alınması.

Veri toplama, projenizin temel taşlarından biridir ve bu aşamada yapılan hatalar tüm modelin performansını etkileyebilir. Bu nedenle, veri toplama sürecine özen göstermek, doğru ve güvenilir veri kaynaklarını seçmek büyük önem taşır.

3. Ham Veriyi Değerli Bilgiye Dönüştürme: Veri Ön İşleme

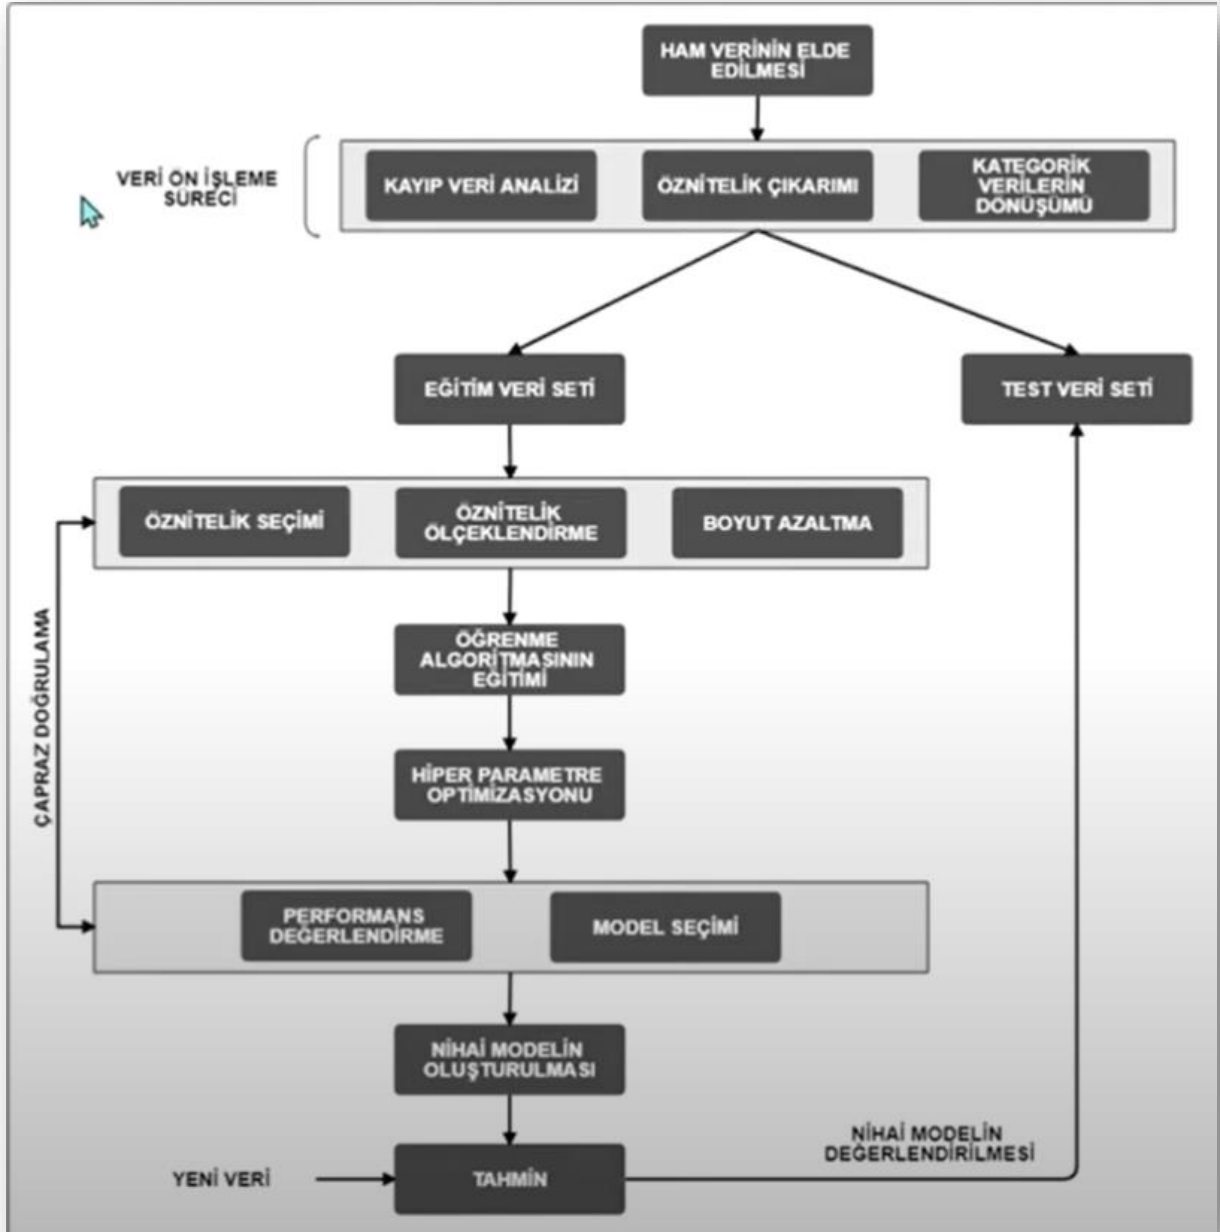
```
# Pandas kütüphanesini yükleme
import pandas as pd

# Veri kümesini yükleme
veri = pd.read_csv('veri_kumesi.csv')

# Eksik verileri doldurma
veri['EksikSutun'].fillna(veri['EksikSutun'].mean(), inplace=True)

# Aykırı değerleri eleme
aykiri_degerler = veri[(veri['Sutun'] > 100) | (veri['Sutun'] < 0)]
veri = veri.drop(aykiri_degerler.index)

# Özellik seçimi
ozellikler = ['Sutun1', 'Sutun2']
veri = veri[ozellikler]
```



Veri ön işleme, ham ve işlenmemiş veriyi modelin anlayabileceği ve öğrenebileceği bir forma getirme sürecidir. Bu aşama, projenin başarısında kritik bir rol oynar.

3.1. Eksik ve Aykırı Değerlerin İşlenmesi

- Eksik veri analizi yaparak hangi özelliklerin eksik olduğunu belirleyin.
- Eksik veriyi uygun yöntemlerle tamamlayın veya silin.
- Aykırı değerleri tespit edin ve bu değerleri işleyin.

3.2. Veri Dönüşüm ve Normalizasyonu

- Veriyi modelin ihtiyaçlarına uygun bir forma dönüştürün.
- Özellik ölçekleme ve normalizasyonu yaparak veriyi standardize edin.
- Kategorik değişkenleri sayısal forma dönüştürün.

3.3. Feature Engineering ve Encoding Yöntemleri

- Var olan özelliklerden yeni özellikler türetin.
- Özellikleri kodlayarak modelin anlayabileceği bir forma getirin.
- Özellik seçimi yaparak modelin performansını optimize edin.

İpuçları

Veri temizliği yaparak modelin doğruluğunu artırabilirsiniz.

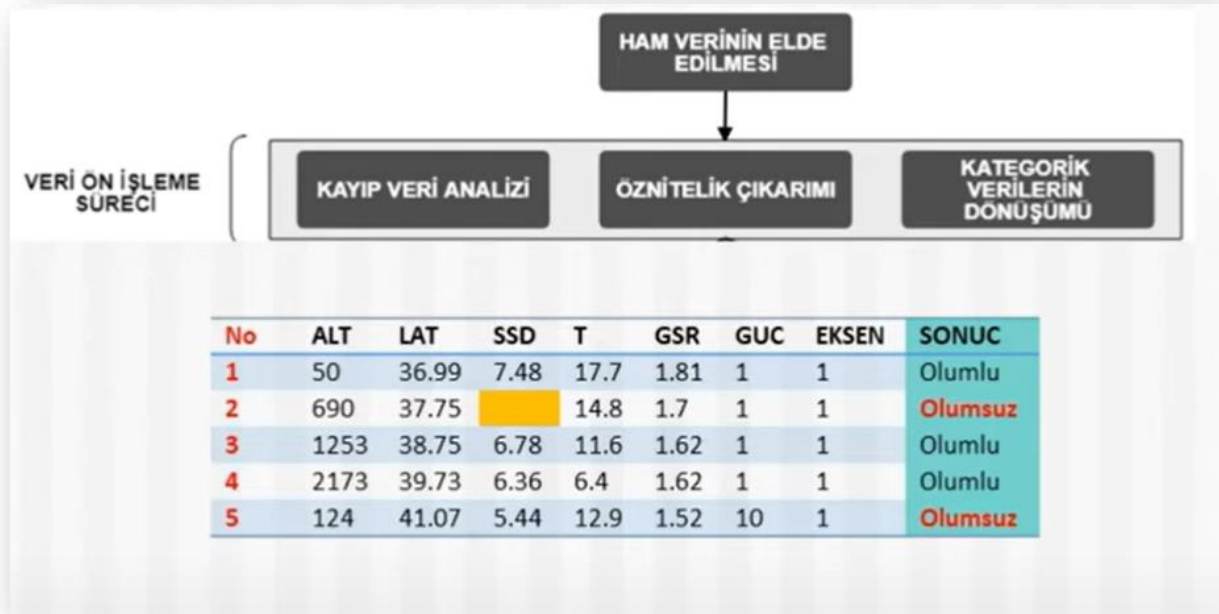
Veriyi dönüştürerek modelin öğrenmesini kolaylaştırabilirsiniz.

Yeni özellikler türeterek modelin başarısını artırabilirsiniz.

Örnek Uygulama

Kredi risk tahmini için veri ön işleme

- **Eksik ve Aykırı Değerlerin İşlenmesi:** Eksik gelir bilgilerinin ortalama ile doldurulması, aykırı kredi skorlarının düzeltilmesi.



- **Veri Dönüşüm ve Normalizasyonu:** Gelir ve borç oranlarının log dönüşümü, yaş ve kredi miktarının normalizasyonu.

- **Feature Engineering ve Encoding:** Kredi skoru ve gelir oranından yeni özellikler türetilmesi, kategorik değişkenlerin one-hot encoding ile dönüştürülmesi.

Veri ön işleme, modelin başarısını doğrudan etkileyen bir süreçtir. Ham veriyi doğru bir şekilde işlemek, modelin öğrenme kapasitesini artırır ve daha doğru sonuçlar almanıza olanak tanır.

4. Veriyi Anlama Sanatı: Keşifsel Veri Analizi (EDA)

Keşifsel Veri Analizi (EDA), veriyi anlama ve yapısal özelliklerini çözümüleme sürecidir. Bu süreç, modelin başarıya ulaşması için kritik bir aşamadır.

4.1. Veri Setinin İstatistiksel Özetlerini Oluşturma

- Veri setinin temel istatistiklerini çıkarın (ortalama, medyan, mod, vb.).
- Verinin dağılımını inceleyin, simetri ve çarpıklığa bakın.

- Veri setinin varyansını ve standart sapmasını analiz edin.

4.2. Görselleştirme Teknikleri ile Veri Yapısının İncelenmesi

- Veri dağılımlarını ve ilişkilerini görselleştirin.
- Histogram, box plot, scatter plot gibi grafikler kullanarak veriyi inceleyin.
- Veri setindeki özellikler arasındaki ilişkileri keşfedin.

4.3. Özelliklerin İlişkilerinin Analizi ve Korelasyon Analizi

- Özellikler arasındaki ilişkileri analiz edin.
- Korelasyon analizi ile özellikler arasındaki bağlantıları belirleyin.
- Multikolinerite (multicollinearity) problemlerini tespit edin ve çözüm üretin.

İpuçları

Veriyi detaylı bir şekilde analiz ederek özellikler arasındaki gizli ilişkileri bulabilirsiniz.

Farklı görselleştirme yöntemleri kullanarak, veri setinin farklı yönlerini keşfedebilirsiniz.

Yüksek korelasyonlu özellikler model üzerinde yanıltıcı etkiler yapabilir, bu yüzden korelasyon analizi dikkatle yapılmalıdır.

Örnek Uygulama

E-ticaret sitesi müşteri verilerinin EDA'sı

- **İstatistiksel Özet:** Müşteri yaş, cinsiyet, alışveriş frekansı gibi özelliklerin istatistiksel özetleri.
- **Görselleştirme Teknikleri:** Müşterilerin alışveriş frekanslarını gösteren histogramlar, cinsiyet dağılımını gösteren pasta grafikleri.
- **Korelasyon Analizi:** Müşteri yaşı ile alışveriş miktarı arasındaki korelasyonun incelenmesi.

Keşifçi Veri Analizi (EDA), veri bilimi projelerinin başarısında önemli bir role sahiptir. Veriyi derinlemesine anlamak, modelin doğruluğunu ve genelleştirme kabiliyetini artırabilir. EDA, model oluşturma aşamasına geçmeden önce gerçekleştirilmesi gereken kritik bir adımdır.

5. Bilgiyi Modellemek: Model Oluşturma

```
# Scikit-learn kütüphanesini yükleme
import sklearn

# Veri kümesini yükleme
from sklearn.datasets import load_iris
veri = load_iris()

# Veri kümesini eğitim ve test veri setlerine ayırma
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(veri.data, veri.target, test
```

Model oluşturma, seçilen algoritmaların veriye uygulanarak belirli bir problemi çözme sürecidir. Bu aşama, makine öğrenimi projelerinde kritik bir rol oynar.

5.1. Algoritma Seçimi ve Veri Setinin Eğitim ve Test Setlerine Bölünmesi

- Problem türünü (sınıflandırma, regresyon, kümeleme, vb.) göz önünde bulundurarak uygulanacak algoritmayı belirleyin.
- Veri setini eğitim ve test setlerine ayırın (genellikle verilerin %70–80'i eğitim, %20–30'u test için ayrılır).
- Seçilen algoritma için modelin yapısını ve parametrelerini konfigüre edin.

5.2. Model Eğitimi ve Değerlendirmesi

- Eğitim setini kullanarak modeli eğitim.
- Cross-validation tekniklerini kullanarak modelin genelleştirme kabiliyetini değerlendirin.
- Modelin performansını test seti üzerinde ölçün.

5.3. Hiperparametre Ayarlama ve Tuning

- Modelin hiperparametrelerini belirleyin ve optimize edin.
- Grid search, random search gibi yöntemlerle en iyi hiperparametre kombinasyonunu bulun.
- Overfitting ve underfitting problemlerini minimize edin.

İpuçları

Farklı model türleri deneyerek en uygun modeli bulabilirsiniz.

Modelin performansını artırmak için hiperparametre optimizasyonunu dikkatlice gerçekleştirin.

Örnek Uygulama

E-ticaret müşteri harcamalarının tahmini için model oluşturma

-Algoritma Seçimi ve Veri Setinin Eğitim ve Test Setlerine

Bölünmesi: Lineer Regresyon veya Rastgele Orman Regresyonu gibi regresyon algoritmalarından birini seçin. Veriyi uygun bir şekilde eğitim ve test setlerine ayırın (genellikle verilerin %70–80'i eğitim, %20–30'u test için ayrılır).

- **Model Eğitimi ve Değerlendirmesi:** Eğitim setini kullanarak modeli eğitin ve modelin performansını test seti üzerinde ölçün, metrikler olarak MAE (Ortalama Mutlak Hata), MSE (Ortalama Kare Hata) veya R^2 gibi regresyon metriklerini kullanın..

- **Hiperparametre Ayarlama ve Tuning:** Grid search veya random search gibi yöntemlerle modelin hiperparametrelerini optimize edin.

6.Model Değerlendirme:

```
# Scikit-learn kütüphanesini yükleme
import sklearn

# Confusion matrix ve diğer metrikleri yükleme
from sklearn.metrics import confusion_matrix, accuracy_score, precision_score,

# Modelinizin tahminleri
y_pred = model.predict(X_test)

# Confusion matrix hesaplama
cm = confusion_matrix(y_test, y_pred)

# Doğruluk, hassasiyet ve geri çağırma hesaplama
accuracy = accuracy_score(y_test, y_pred)
precision = precision_score(y_test, y_pred)
recall = recall_score(y_test, y_pred)
```

Model oluşturma, makine öğrenimi sürecinin en kritik aşamalarından biridir. Bu aşamada, doğru algoritmanın seçilmesi, verinin doğru bir şekilde bölünmesi ve hiperparametrelerin doğru bir şekilde ayarlanması modelin başarısında belirleyici faktörlerdir.

Model değerlendirme, oluşturulan modelin performansını ölçme ve doğrulama sürecidir. Bu aşama, modelin gerçek dünya verileri üzerinde ne kadar iyi çalıştığını belirler.

6.1. Performans Metriklerinin Seçimi ve Uygulanması

- Modelin başarısını ölçmek için uygun metrikleri seçin.
- Sınıflandırma için accuracy, recall, precision; regresyon için R2, MSE, RMSE gibi metrikleri kullanın.
- Seçilen metrikleri model üzerinde uygulayın ve değerlendirin.

6.2. Confusion Matrix, ROC Eğrisi ve AUC Değerlendirmesi

- Modelin doğruluğunu ve yanlış sınıflandırmalarını karışıklık matrisi ile değerlendirin.
- ROC eğrisi ve AUC ile modelin ayırt edici yeteneğini ölçün.
- Modelin sınıflandırma performansını bu tekniklerle detaylıca analiz edin.

6.3. Modelin Genelleştirme Kabiliyetinin Değerlendirilmesi

- Modelin bilinmeyen verilere olan adaptasyonunu test edin.
- Overfitting veya underfitting problemlerini tespit edin.
- Modelin gerçek dünya verileri üzerindeki performansını değerlendirin.

İpuçları

Modelin performansını daha doğru bir şekilde anlamak için çeşitli metrikleri kullanın.

Dengesiz veri setleri üzerinde çalışırken, precision, recall, F1-score gibi metrikleri kullanın.

Modelin genelleştirme kabiliyetini daha doğru ölçebilmek için cross validation (çapraz doğrulama) tekniklerini kullanın.

Örnek Uygulama

Sağlık sektörü için hastalık teşhisi modelinin değerlendirilmesi

- **Performans Metriklerinin Seçimi ve Uygulanması:** Hassasiyet ve hatırlama metriklerinin kullanılması.
- **Confusion Matrix, ROC Eğrisi ve AUC Değerlendirmesi:** Confusion matrix ile yanlış pozitif ve yanlış negatif oranların belirlenmesi.
- **Modelin Genelleştirme Kabiliyetinin Değerlendirilmesi:** Çapraz doğrulama ile modelin genelleştirme başarısının test edilmesi.

Model değerlendirme, modelin başarısını ölçen kritik bir süreçtir. Bu aşama, modelin gerçek dünya verileri üzerinde ne kadar iyi genelleştirdiğini ve belirlenen problemleri ne kadar iyi çözdüğünü gösterir.

7. Modeli Mükemmelleştirme: Model Optimizasyonu

Model optimizasyonu, oluşturulan modelin performansını artırmak için yapılan iyileştirmeler ve düzenlemeler sürecidir. Bu aşama, modelin daha doğru ve etkili olmasını sağlar.

7.1. Hiperparametre Optimizasyonu Yöntemleri

- En uygun hiperparametre değerlerini bulmak için çeşitli yöntemleri kullanın.
- Grid search ve random search gibi yöntemlerle modelin performansını artırın.
- En iyi hiperparametre kombinasyonunu seçin.

7.2. Feature Selection ve Dimensionality Reduction Teknikleri

- Modelin karmaşıklığını azaltmak ve performansını artırmak için önemli özellikleri seçin.
- Principal Component Analysis (PCA) gibi yöntemlerle boyut indirgeme yapın.
- En etkili özellikleri belirleyin ve modeli bu özellikler üzerinde eğitin.

7.3. Ensemble Metodlar ve Stacking

- Farklı modellerin güçlerini birleştirerek daha güçlü bir model oluşturun.
- Random Forest, Gradient Boosting gibi ensemble metodları kullanarak modelin doğruluğunu artırın.
- Stacking yöntemiyle farklı modellerin tahminlerini birleştirin.

İpuçları

Model optimizasyonunu adım adım ve sistematik bir şekilde yapın.

Veri temizliği ve ön işleme, model optimizasyonunun bir parçasıdır; bu adımlar model performansını büyük ölçüde etkileyebilir.

Ensemble metodlarda model çeşitliliğini sağlayarak daha dengeli ve güçlü modeller oluşturun.

Örnek Uygulama

Enerji tüketim tahmini için model optimizasyonu

- **Hiperparametre Optimizasyonu Yöntemleri:** Grid search kullanarak en uygun hiperparametreleri bulma.

- **Feature Selection ve Dimensionality Reduction:** Feature engineering ve PCA kullanarak veri setinin boyutunu azaltma

- **Ensemble Metodlar ve Stacking:** Random Forest ve Gradient Boosting modellerini birleştirerek daha güçlü bir model oluşturma.

Model optimizasyonu, makine öğrenimi projelerinde modelin başarısını maksimize etmek için kritik bir adımdır. Bu süreçte yapılan iyileştirmeler, modelin daha doğru ve güvenilir tahminler yapmasını sağlar.

8. Bilgiyi Dünyaya Sunma: Modeli Deploy Etme

Modeli deploy etme yani dağıtım, eğitilmiş makine öğrenimi modelinin kullanıcıların erişebileceği bir platforma veya servise entegre edilmesi sürecidir. Bu adım, modelin pratikte kullanılabilir hale gelmesini sağlar.

8.1. Modelin Üretim Ortamına Taşınması

- Modeli, kullanıcıların erişebileceği bir platforma yerleştirin.
- Modelin üretim ortamında sorunsuz çalışmasını sağlayın.
- Modelin performansını ve sağlığını sürekli izleyin.

8.2. API'ler ve Servisler Aracılığıyla Erişilebilirlik

- Modeli bir API olarak sunarak erişilebilir kılın.
- Farklı uygulamalar ve servislerle entegrasyonu sağlayın.
- Kullanıcıların modeli kolayca kullanabilmelerini sağlayın.

8.3. Performans ve Ölçeklenebilirlik Optimizasyonu

- Modelin yüksek taleplere cevap verebilmesi için ölçeklenebilirliğini sağlayın.
- Modelin hız ve performansını optimize edin.

- Kaynak kullanımını ve maliyetleri dikkate alarak modeli optimize edin.

İpuçları

Modelin performansını sürekli izleyerek zaman içindeki değişimleri takip edin.

Modelin, API'nin ve servisin düzgün bir şekilde dokümantasyonunu yapın.

Kullanıcı geri bildirimlerini toplayarak modeli iyileştirin ve geliştirin.

Örnek Uygulama

Sağlık teşhisi modelinin bir mobil uygulama üzerinden dağıtımı

- **Modelin Üretim Ortamına Taşınması:** Modelin bir cloud servise yerleştirilmesi ve sürekli izlenmesi.

- **API'ler ve Servisler Aracılığıyla Erişilebilirlik:** Modelin bir API olarak sunulması ve mobil uygulama ile entegrasyonu.

- **Performans ve Ölçeklenebilirlik Optimizasyonu:** Modelin ölçeklenebilirliğinin sağlanması ve performans iyileştirmeleri.

Model dağıtımı, makine öğrenimi projelerinin son ve kritik aşamasıdır. Bu adım, modelin gerçek dünya kullanıcıları tarafından kullanılabilir hale gelmesini sağlar.

9. Sürekli İyileştirme ve Yenilik: Model Güncelleme ve Bakım

Model güncelleme ve bakım, makine öğrenimi modelinin sürekli olarak izlenmesini, güncellenmesini ve iyileştirilmesini içerir. Bu süreç, modelin sürekli olarak doğru ve etkili sonuçlar üretmesini sağlar.

9.1. Modelin Sürekli İzlenmesi ve Değerlendirilmesi

- Modelin performansını ve doğruluğunu sürekli olarak izleyin.
- Kullanıcı geri bildirimleri ve yeni gelen verilere dayalı olarak modeli değerlendirin.

- Modelin sađlıđını ve stabilitesini s¼rekli kontrol edin.

9.2. Modelin G¼ncellenmesi ve İyileřtirilmesi

- Yeni verilerle modeli d¼zenli olarak g¼ncelleyin.
- Modelin performansını artırmak i¼in iyileřtirmeler yapın.
- Modelin dođruluđunu ve genelleřtirme kabiliyetini korumak i¼in optimize edin.

9.3. Yenilikçi Yaklařımlar ve Teknolojilerin Entegrasyonu

- Yeni makine ¼đrenimi teknikleri ve yaklařımları ile modeli g¼çlendirin.
- Modelin performansını artırmak i¼in en son arařtırmalardan ve geliřmelerden faydalanın.
- Yenilikçi ¼öz¼mler geliřtirerek modeli daha etkili hale getirin.

İpuçları

Modelin performansını korumak i¼in proaktif bakım uygulayın.

Modelin yeni verilerle s¼rekli ¼đrenmesini sađlayarak adaptasyon kabiliyetini artırın.

Makine ¼đrenimi alanındaki yenilikleri takip edin ve modelinizi bu yeniliklere g¼re g¼ncelleyin.

Örnek Uygulama

T¼keticiler tercihleri tahmin modelinin g¼ncellenmesi ve bakımı

- **Modelin S¼rekli İzlenmesi ve Deđerlendirilmesi:** Modelin performans metriklerinin s¼rekli olarak izlenmesi.

- **Modelin G¼ncellenmesi ve İyileřtirilmesi:** Yeni t¼keticiler verileri ile modelin d¼zenli olarak g¼ncellenmesi.

- **Yenilikçi Yaklařımlar ve Teknolojilerin Entegrasyonu:** En son makine ¼đrenimi arařtırmaları ve teknikleri ile modelin iyileřtirilmesi.

Model gncelleme ve bakım, makine ğrenimi modelinin srekli olarak etkili ve doęru alıřmasını saęlar. Srekli iyileřtirme ve yenilik, modelin srekli olarak geliřmesine ve adaptasyon kabiliyetinin artmasına olanak tanır.